

SAUSAU - predmetni projekat

TELCO CUSTOMER CHURN CLASSIFICATION

1.Opis teme

1.1 Poslovni i inženjerski problem

Zadatak ovog projekta je razvoj sistema mašinskog učenja za predviđanje odlaska korisnika (**Customer Churn**) u telekomunikacionoj kompaniji. Zadržavanje postojećih korisnika je višestruko jeftinije od akvizicije novih, te rano prepoznavanje klijenata koji nameravaju da raskinu ugovor omogućava kompaniji da pravovremeno reaguje personalizovanim marketinškim akcijama ili popustima.

Sa inženjerske strane, problem je definisan kao **binarni klasifikacioni zadatak** nad tabelarnim podacima:

- **Klasa 0 (No Churn):** Korisnik ostaje veran kompaniji.
- **Klasa 1 (Churn):** Korisnik raskida ugovor.

1.2 Struktura i disbalans skupa podataka

Dataset (`telco_data.csv`) sadrži **7043 instanci** (korisnika) i **21 atribut**. Originalni skup podataka karakteriše umereni prirodni disbalans klasa, gde otprilike **73%** korisnika pripada klasi *No Churn*, dok **27%** predstavlja *Churn* klasu. Ovaj disbalans zahteva posebne napredne tehnike uzorkovanja tokom treninga kako modeli ne bi favorizovali većinsku klasu.

2.Priprema skupa podataka

Faza pripreme podataka realizovana je unutar skripte `data_preparation.py` kroz modularne funkcije koje obezbeđuju stabilnost sistema i sprečavaju curenje podataka (*data leakage*).


2.1 Čišćenje i učitavanje podataka (`load_and_clean_data`)

- **Uklanjanje irelevantnih atributa:** Kolone `customerID` (jedinostveni identifikator bez prediktivne moći) i `gender` (koji se pokazao statistički neutralnim) uklanjaju se na samom početku.
- **Rešavanje anomalija u tipovima podataka:** Atribut `TotalCharges` se inicijalno učitava kao tekstualni tip zbog prisustva praznih stringova (" ") kod novih korisnika sa trajanjem ugovora (`tenure`) od 0 meseci. Ovi prazni prostori se pronalaze regularnim izrazom `' '` i zamenjuju sa `NaN`.
- **Imputacija nedostajućih vrednosti:** Konvertovana kolona `TotalCharges` se popunjava **medijanom** trening skupa, čime se neutrališe uticaj ekstremnih vrednosti.
- **Uklanjanje duplikata:** Funkcijom `drop_duplicates()` čisti se tabela od redundantnih zapisa.


2.2 Eksplorativna analiza podataka (**perform_eda**)

Pre bilo kakvih transformacija, generišu se i čuvaju ključni grafikoni:

1. **Distribucija Churn-a po tipu ugovora (**eda_churn_by_contract.png**)**: Eksplicitno pokazuje da korisnici sa kratkoročnim ugovorima (mesec-za-mesec) imaju drastično veću stopu napuštanja kompanije od onih sa jedno- ili dvogodišnjim ugovorima.



2. **Korelaciona matrica (**eda_correlation_matrix.png**)**: Računa Pearson-ov koeficijent korelacije za numeričke attribute (**tenure**, **MonthlyCharges**, **TotalCharges**), mapirajući snažnu linearnu zavisnost između trajanja ugovora i ukupnih troškova.



2.3 Transformacija i enkodiranje (**preprocess_data**)

- **Ciljna promenljiva:** Primenjuje se `LabelEncoder` koji mapira **Yes** - 1 i **No** -0.
- **Kategorički atributi:** Svi kategorički faktori prolaze kroz postupak *One-Hot Enkodiranja* pomoću `pd.get_dummies()`. Eksplicitno se koristi parametar `drop_first=True` kako bi se izbegla zamka dummy promenljivih (*Dummy Variable Trap*) i sprečila multikolinearnost u linearnim modelima.

2.4 Podela i skaliranje podataka (**split_and_save_data**)

Podela (70/15/15): Skup se deli na trening (70%), validacioni (15%) i testni skup (15%). Koristi se parametar `stratify=y` kako bi se u svakom podskupu strogo očuvao inicijalni odnos klasa (73:27).

Strogo skaliranje: `StandardScaler` računa srednju vrednost i devijaciju **isključivo nad trening skupom** (`fit_transform`). Validacioni i testni skupovi se skaliraju isključivo na osnovu tih parametara (`transform`), eliminišući bilo kakav oblik *data leakage-a*.

3. Treniranje modela i selekcija atributa

Proces treniranja se nalazi u skripti `train.py` i fokusiran je na rešavanje problema nebalansiranih klasa kroz **SMOTEENN** (kombinacija metoda **SMOTE** i **ENN**) koji predstavlja hibridnu tehniku uzorkovanja koja se koristi u mašinskom učenju za rešavanje problema izrazito neuravnoteženih skupova podataka (engl. *imbalanced datasets*).

Njen glavni zadatak je modifikacija skupa podataka za treniranje kako bi se sprečilo da model ignoriše manjinsku klasu (klasu koja ima znatno manje uzoraka od većinske). Za razliku od jednostavnih pristupa, SMOTEENN istovremeno primenjuje i povećavanje (oversampling) i smanjivanje (undersampling) broja uzoraka kroz dve uzastopne faze:

1. Faza: Oversampling pomoću SMOTE-a

Prvi korak rešava problem nedostatka podataka manjinske klase. Algoritam ne kopira postojeće podatke (što bi dovelo do prenaučенosti, odnosno *overfittinga*), već matematičkom interpolacijom između najbližih suseda generira potpuno nove, sintetičke uzorke manjinske klase. Na taj način se veštački povećava prisustvo manjinske klase u skupu podataka.

2. Faza: Undersampling (čišćenje) pomoću ENN-a

Nakon prve faze, granica između klasa često postaje mutna i preklapajuća jer SMOTE može da stvori sintetičke tačke duboko u teritoriji većinske klase. Zato se primenjuje **ENN (Edited Nearest Neighbors)** algoritam koji radi kao filter za čišćenje:

- Za svaki uzorak u setu podataka analiziraju se njegovi najbliži susedi (najčešće tri).
- Ako se klasa tog uzorka razlikuje od klase većine njegovih suseda, taj uzorak se uklanja iz skupa podataka.

3.1 Pregled treniranih modela

Modeli su spakovani u cevovode (*Pipelines*) gde se SMOTE primenjuje dinamički samo na trening uzorcima u svakom koraku, dok testni i validacioni podaci ostaju netaknuti:

1. **Logistic Regression:** Linearni baseline model konfigurisan sa i L2 regularizacijom kako bi se uspostavila stabilna polazna tačka.
2. **Random Forest:** Bagging ansambl model koji se bori protiv visoke varijanse usrednjavanjem odluka skupa nezavisnih stabala.
3. **Gradient Boosting:** Sekvencijalni boosting model koji iterativno minimizuje rezidualne greške prethodnih stabala.
4. **K-Nearest Neighbors (KNN):** Ne-parametarski algoritam zasnovan na distancama k-suseda u skaliranom prostoru.

5. **Support Vector Machine (SVM):** Model sa RBF kernelom unutar `CalibratedClassifierCV` kalibracije, koja omogućava stabilno generisanje verovatnoća (`predict_proba`) neophodnih za ROC-AUC metriku.
6. **XGBoost:** Ekstremno optimizovana implementacija gradijentnog boosting-a sa ugrađenom regularizacijom i parametrom `scale_pos_weight`

3.2 Hiperparametarska optimizacija (GridSearchCV) i Podešavanje praga odlučivanja

U fazi razvoja modela mašinskog učenja, proces optimizacije je podeljen u dva nivoa kako bi se osigurala maksimalna robusnost i prilagođenost biznis ciljevima projekta:

1. **Unutrašnja optimizacija pomoću GridSearchCV:** Za svaki algoritam (Logistic Regression, Random Forest, Gradient Boosting, KNN, SVM, XGBoost) definisan je prostor hiperparametara kroz koji se pretražuje korišćenjem petostruke unakrsne validacije (`cv=5`). Kao primarna klasifikaciona metrika tokom ove faze optimizacije izabran je **F1-skor**. Ovaj izbor je ključan jer F1-skor predstavlja harmonijsku sredinu preciznosti i odziva, čime se direktno adresira problem neuravnoteženosti klasa i izbegava da modeli favorizuju većinsku klasu.
2. **Eksterna optimizacija praga (Threshold Tuning) na validacionom skupu:** Podrazumevani klasifikacioni prag od 0.5 često nije optimalan kada se radi sa podacima koji su prošli kroz hibridno balansiranje (SMOTEENN) ili kada poslovni problem zahteva asimetričnu osetljivost na greške. Zbog toga je nakon pronalaženja najboljih parametara kroz unakrsnu validaciju uvedena funkcija `find_best_threshold`. Ova funkcija uzima istrenirani cevovod (`pipeline`), generiše verovatnoće na potpuno izdvojenom **validacionom skupu** podataka (`X_val`, `y_val`) i kroz iterativnu pretragu u opsegu od 0.3 do 0.8 (sa korakom 0.02) pronalazi specifičan prag koji maksimizuje F1-skor.

Ova metodologija sprečava "curenje" podataka (*data leakage*), jer se unutrašnji parametri strukture stabala ili koeficijenti linearnih modela podešavaju na trening setu kroz kros-validaciju, dok se finije kalibrisanje same granice odlaska korisnika vrši na validacionom setu. Rezultujući optimalni pragovi (poput 0.72 za Logistic Regression ili 0.52 za Gradient Boosting) čuvaju se u fajlu `optimal_thresholds.pkl` i primenjuju prilikom finalne evaluacije na testnom skupu, obezbeđujući stabilne i visoko precizne performanse u produkcionom okruženju.

3.3 Selekcija atributa (Feature Selection - Reduced Model)

Koristeći ugrađeni atribut `.feature_importances_` iz istreniranog *Gradient Boosting* modela, algoritam selektuje **top 5 najznačajnijih atributa**:

- *Contract* (Tip ugovora)
- *tenure* (Dužina ostanka)
- *MonthlyCharges* (Mesečni račun)

- *PaymentMethod* (Način plaćanja)
- *InternetService* (Tip interneta)

Nakon ekstrakcije, pokreće se trening sedmog, **redukovanog modela** (**Gradient Boosting Reduced**), koji uči isključivo na ovih 5 izdvojenih kolona, demonstrirajući performanse sistema u uslovima smanjene dimenzionalnosti prostora.

4. Metrike

Skripta **evaluate.py** vrši rigorozno i objektivno testiranje svih 7 sačuvanih modela na potpuno izolovanom testnom skupu podataka koji modeli nisu videli tokom treninga ni tokom SMOTE sinteze.

4.1 Definisanje evaluacionih metrika

Za ocenu kvaliteta klasifikacije izračunava se pet ključnih metrika:

$$\text{Accuracy} = (TP + TN) / (TP + TN + FP + FN)$$

- **Accuracy (Tačnost):** Ukupan procenat tačnih predikcija. Može biti varljiva kod nebalansiranih skupova.

$$\text{Precision} = TP / (TP + FP)$$

Precision (Preciznost): Od svih korisnika za koje je model predvideo da će otići, koliki procenat stvarno odlazi. Visoka preciznost smanjuje rizik od lažnih uzbuna (FP).

$$\text{Recall} = TP / (TP + FN)$$

- **Recall (Odziv / Senzitivnost):** Od svih korisnika koji stvarno odlaze, koliki procenat je model uspeo da locira. Najvažnija metrička veličina za biznis, jer smanjuje broj neprepoznatih odlazaka (FN)


$$\text{F1-Score} = 2 * (\text{Precision} * \text{Recall}) / (\text{Precision} + \text{Recall})$$

- **F1-Score:** Harmonijska sredina preciznosti i odziva. Pruža jedinstvenu meru balansa između FP i FN grešaka.
- **ROC-AUC (Area Under the Receiver Operating Characteristic):** Mera sposobnosti modela da razlikuje klase na osnovu dodeljenih verovatnoća, nezavisno od izabranog praga (threshold-a) klasifikacije.


4.2 Automatizacija evaluacije kroz kod (**evaluate.py**)

Skripta automatski izvršava sledeće korake:


1. Učitava `test.csv` i ekstrahuje ciljnu promenljivu.
2. Preuzima listu `top_features.pkl` za potrebe redukovanog modela.
3. Iterira kroz mapiranih 7 modela, izvršava predikcije i računa pomenute metrike preko `sklearn.metrics`.
4. Konstruiše **matrice konfuzije** pomoću `sns.heatmap` sa `Purples` paletom boja, ispisujući sve izračunate metrike direktno u naslov grafikona radi lakše vizuelne analize. Grafici se sačuvavaju sa `dpi=300` u `results/figures/`.
5. Konvertuje listu performansi u `pd.DataFrame` i eksportuje konačni uporedni fajl `final_model_comparison_report.csv` u `results/metrics/`.




Zapažanje: Logistička regresija i KNN sa SMOTE tehnikom pokazuju izuzetno visok **Recall (odziv)**. To znači da uspešno pronalaze najveći broj korisnika koji zaista žele da odu (malo imaju *False Negative* grešaka), ali po cenu nešto veće količine lažnih uzbuna (*False Positives*), što im obara *Precision*.



Zapažanje: Stabilni modeli koji ujednačavaju greške, ali naginju ka konzervativnijem predviđanju odlaska klijenata.



Zapažanje: Ovo su najbolji modeli u pogledu balansa. Oni ostvaruju visok F1-Score i ROC-AUC jer uspevaju da zadrže visok odziv (Recall), a istovremeno drastično smanjuju broj lažno pozitivnih grešaka u odnosu na Logističku regresiju.



Zapažanje: Iako koristi samo 5 atributa (Contract, tenure, MonthlyCharges...), ovaj model zadržava skoro 90-95% performansi punog modela, što dokazuje izvanrednu selekciju atributa.

5. Implementacija korisničkog interfejsa i deployment modela

U cilju demonstracije praktične primenljivosti razvijenog sistema u realnom poslovnom okruženju, realizovana je interaktivna veb-aplikacija pomoću radnog okvira **Streamlit**. Ova aplikacija omogućava menadžerima korisničkog servisa i marketing timu donošenje odluka u realnom vremenu direktnim unosom karakteristika korisnika.

Za deployment je svesno odabran **redukovani model Gradient Boosting-a** (`gradient_boosting_reduced_model.pkl`), koji donosi odluke na osnovu svega 5 najznačajnijih atributa identifikovanih u fazi selekcije atributa (*Feature Selection*). Ovakav pristup drastično pojednostavljuje korisnički interfejs, smanjuje kognitivno opterećenje operatera i eliminiše potrebu za unosom preko dvadeset kompleksnih parametara, zadržavajući pritom visoku tačnost predikcije.

5.1 Arhitektura i logika rada aplikacije

Aplikacija funkcioniše po principu klijent-server arhitekture unutar lokalnog okruženja i izvršava se kroz sledeće faze:

1. **Učitavanje resursa:** Prilikom pokretanja, aplikacija vrši proveru postojanja i dinamičko učitavanje serijalizovanog modela i liste odabranih atributa pomoću biblioteke `joblib`. Ukoliko datoteke nisu pronađene, sistem bezbedno prekida rad uz ispisivanje korisničke poruke o grešci.
2. **Dinamičko generisanje interfejsa:** Na osnovu učitane liste iz `top_features.pkl`, aplikacija automatski prepoznaje tipove podataka i generiše odgovarajuće UI komponente za unos:
 - **Kontrolni klizači (Sliders):** Primenjeni za kontinualne numeričke attribute (`tenure`, `MonthlyCharges`, `TotalCharges`) sa definisanim opsezima, podrazumevanim vrednostima i koracima (step-om) koji odgovaraju realnim domenima podataka.
 - **Padajući meniji (Selectboxes):** Primenjeni za kategoričke binarne attribute koji su prošli proces One-Hot enkodiranja (`InternetService_Fiber optic`, `PaymentMethod_Electronic check`). Korisniku se prikazuju intuitivne opcije ("Da" / "Ne"), koje se unutar koda interno mapiraju u binarne vrednosti 1 i 0.
3. **Predikcija i analiza rizika:** Klikom na dugme "Pokreni predikciju", uneti podaci se pakuju u `pandas.DataFrame` objekat, vrši se usklađivanje redosleda kolona sa originalnim trening skupom, a potom se prosleđuju modelu. Pored same binarne klase (0 ili 1), model pomoću metode `.predict_proba()` računa i tačan procentualni rizik od odlaska korisnika.

6. Analiza rezultata i zaključak

Nakon izvršavanja `evaluate.py` pipeline generiše uporednu tabelu performansi koja daje jasne inženjerske smernice:

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC
XGBoost	0.753	0.520	0.719	0.628	0.852
Gradient Boosting	0.769	0.541	0.805	0.647	0.848
Logistic Regression	0.756	0.525	0.805	0.635	0.841
SVM	0.734	0.497	0.845	0.626	0.835
Random Forest	0.750	0.516	0.794	0.626	0.839
KNN	0.739	0.503	0.787	0.614	0.772
<i>Grad. Boosting Reduced (Top 5)</i>	<i>0.749</i>	<i>0.516</i>	<i>0.755</i>	<i>0.613</i>	<i>0.829</i>

5.1 Poređenje modela (Interpretacija rezultata)

A. Gradient Boosting (SMOTEENN) – Šampion u detekciji odlaska (Max Recall)

Ovaj model je ostvario najviši odziv (**87.0%**) i uspešno identifikovao čak **241 korisnika** koji će otići, propustivši samo 36 njih (najmanji broj lažno negativnih - FN).

- **Biznis implikacija:** Ako je kompaniji primarni cilj da po svaku cenu pronađe korisnike koji žele da odu i ponudi im retencione pakete, ovo je najbolji model. Nuspojava je niža preciznost (49.6%) i veći broj lažno alarmiranih korisnika (245 FP).

B. Logistic Regression (SMOTEENN) – Najbolji balans (Max F1 & Acc)

Iznenadjujuće visoke performanse za linearni model nakon SMOTEENN tretmana. Ostvario je najveću tačnost (**75.6%**) i najbolji opšti balans između preciznosti i odziva (**F1: 0.635**). Uspešno hvata 223 *Churn* korisnika uz umeren broj lažnih uzbuna (202).

C. XGBoost i Random Forest (SMOTEENN) – Stabilni i ujednačeni

Oba ansambl modela bazirana na stablima odlučivanja pokazuju stabilne performanse sa F1-skorom oko **0.628**. XGBoost ima blagu prednost u tačnosti (75.3%) i preciznosti (52.0%) u odnosu na Random Forest, ali imaju skoro identičan broj uspešno detektovanih korisnika (219 naspram 220).

D. SVM i KNN (SMOTEENN) – Geometrijski modeli

- **SVM** pokazuje veoma solidan odziv (**84.5%**, 234 tačna pogodka), što ukazuje da mu je ENN čišćenje granica prostora izuzetno pomoglo da konstruiše kvalitetnu hiperravan.
- **KNN** zaostaje za ostalim algoritmima sa najnižim F1-skorom (0.614) u ovoj SMOTEENN grupi.

E. Gradient Boosting Reduced (Top 5 atributa bez SMOTEENN-a)

Ovaj model služi kao kontrolni primer. Iako ima visoku tačnost (74.9%) i solidnu preciznost usled smanjenog šuma sa samo 5 ključnih atributa, njegov odziv iznosi **75.5%** (propušta čak 68 korisnika). To jasno dokazuje da SMOTEENN značajno podiže sposobnost modela da prepozna manjinsku klasu (skok sa 75.5% na 87.0% kod punog Gradient Boosting modela).

5.2 Poslovne preporuke

1. **Strategija ranog zadržavanja:** S obzirom na to da je tip ugovora (*Contract*) najvažniji atribut, menadžment treba da kreira stimulativne popuste za prelazak sa Month-to-month ugovora na stabilnije jednogodišnje aranžmane.
2. **Izbor produkcionog modela:** Ukoliko su računarski resursi ograničeni, redukovani model sa 5 atributa je idealan za produkciju zbog brzine i jednostavnosti. Ako se teži maksimalnim performansama, **XGBoost (SMOTE)** treba postaviti kao primarni klasifikator.